Activation Checkpointing

Для экономии памяти при обучении больших моделей с большим контекстом используют алгоритм Activation Checkpointing. Предлагается реализовать данный алгоритм для модельной архитектуры Transformer. При реализации нельзя использовать уже готовый Activation Checkpointing, представленный в библиотеке torch.

Краткая суть алгоритма: у нас есть Transformer, состоящий из n блоков. Внутри каждого блока сохраняется m активаций при вызове forward. Т. е. без Activation Checkpointing мы должны сохранить m * n активаций. Activation Checkpointing сохраняет только вход в блок трансформера (одну активацию), и пересчитывает forward для каждого блока при вызове backward. Т. е. тут на GPU будут сохраняться m + n активаций в пике.

Рекомендация: работать с большим контекстом в 10k+ токенов, чтоб более явно наблюдать эффект от сокращения памяти, потребляемой активациями.

Ожидаемый результат: код алгоритма и профили по памяти и скорости работы. Ниже представлены ожидаемые профили по памяти с базовым Activation Checkpoinitng.
Про профайлинг можно почитать тут (по памяти и по скорости)
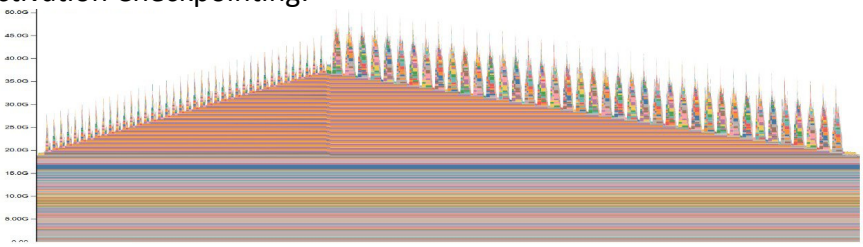
Activation Checkpointing: